

Tổng quan về xử lý tiếng nói

👤 Người tạo Empty

📁 Module Audio Processing

📁 Trạng thái Empty

☰ Note Empty

📅 Đã trình bày Empty

📁 Sub-module Empty

📁 Submodule 2 Empty

Số lượng thành ... Empty

Comments

 Add a comment...

Âm, âm tiết, âm vị

Âm tiết

Trong tiếng Anh và nhiều ngôn ngữ khác, 1 từ được ghép bởi nhiều âm tiết. VD từ "want" có 1 âm tiết, "wanna" có 2 âm tiết, "computer" có 3 âm tiết Trong khi đó trong tiếng Việt, gần như mọi âm tiết đều mang ngữ nghĩa nên ta có thể coi âm tiết là 1 từ. Một âm tiết thường là một nguyên âm, có hoặc không có các phụ âm đi kèm.

Nguyên âm: Tiếng anh là **vowel**, là những âm thanh được phát ra mà không có sự cản trở trong đường hô hấp, không bị ngắt quãng. Trong tiếng Việt có các nguyên âm: a, o, e, i, u ... Để hình dung, bạn thử đọc chữ /a/ kéo dài xem, ta có thể tạo ra tiếng /a/ liên tục, không có sự ngắt quãng

nào.

Phụ âm: Tiếng Anh là **consonants**, khác với nguyên âm, phụ âm được tạo ra với sự đóng hoàn toàn hoặc 1 phần của thanh quản, làm phá vỡ, ngắt quãng dòng nguyên âm, tạo ra những khoảng ngắt quãng rõ ràng. Hãy thử đọc 1 câu đã lược bỏ tất cả phụ âm, bạn sẽ thấy mình chỉ ú ớ như 1 đứa vừa đi khám răng về.

Âm vị và âm (phoneme and phone)


Vowels			
Phoneme	IPA Symbol	Graphemes	Examples
25	æ	a, ai, au	cat, plaid, laugh
26	eɪ	a, ai, eigh, aigh, ay, er, et, ei, au, a_e, ea, ey	bay, maid, weigh, straight, pay, foyer, filet, eight, gauge, mate, break, they
27	e	e, ea, u, ie, ai, a, eo, ei, ae	end, bread, bury, friend, said, many, leopard, helper, aesthetic
28	i:	e, ee, ea, y, ey, oe, ie, i, ei, eo, ay	be, bee, meat, lady, key, phoenix, grief, ski, deceive, people, quay
29	ɪ	i, e, o, u, ui, y, ie	it, england, women, busy, guild, gym, sieve
30	aɪ	i, y, igh, ie, uy, ye, ai, is, elgh, i_e	spider, sky, night, pie, guy, stye, aisle, island, height, kite

Âm vị: Tiếng anh là **phoneme**, trong nhiều loại ngôn ngữ, một kí tự/cụm kí tự (letter) trong các từ khác nhau có thể có nhiều cách phát âm khác nhau. Bảng chữ cái latin có 26 chữ cái nhưng có tới 44 phoneme. VD chữ **"ough"** trong câu sau có tới 6 kiểu phát âm.


Though I **coughed** **roughly** and hic**coughed** **throughout** the lecture, I still thought I could **plough** **through** the rest of it.

Trong các bài toán Text to Speech, người ta cần chuyển đổi từ dạng chữ viết sang dạng chuỗi các âm vị. Chữ tiếng Việt của chúng ta có tính tượng thanh cao hơn, có tính thống nhất cao giữa cách viết và cách đọc. Đó có thể là 1 thuận lợi của chúng ta khi làm việc với tiếng Việt.

Âm: Tiếng anh là **phone** là sự hiện thực hoá âm vị. Cùng 1 phoneme nhưng mỗi người lại có 1 giọng đọc khác nhau, VD cùng từ "ba" nhưng giọng nam khác giọng nữ, giọng người A khác giọng người B. Để dễ phân biệt giữa "phoneme" và "phone" thì bạn có thể quan sát hình dưới đây. Hình ảnh mô tả câu "she just had a baby" được tách thành các âm vị (phoneme) ở hàng dưới và được hiện thực hoá thành các "phone" (hình ảnh các sóng âm thanh).




Nguyên lý hình thành tiếng nói.



Đầu tiên, một luồng hơi được đẩy lên từ phổi tạo áp lực lên thanh quản (Vocal folds). Dưới áp lực đó, thanh quản mở ra giúp luồng không khí thoát qua, áp lực giảm xuống khiến thanh quản tự động đóng lại. Việc đóng lại như vậy lại khiến áp lực tăng lên và quá trình tái diễn. Các chu kỳ đóng/mở thanh quản này liên tục tái diễn, tạo ra các tần số sóng âm với tần số cơ bản khoảng 125Hz với nam, 210Hz với nữ. Đó là lí do giọng của nữ giới thường có xu hướng cao hơn giọng nam. Tần số này gọi là **fundamental frequency F0**.

Như vậy thanh quản đã tạo ra các tần số sóng âm cơ bản. Tuy nhiên để hình thành lên tiếng nói còn cần đến các cơ quan khác như: vòm họng, khoang miệng, lưỡi, răng, môi, mũi... Các cơ quan này hoạt động như 1 bộ "cộng hưởng" giống hộp đàn guitar, nhưng có khả năng thay đổi hình dạng linh hoạt. Bộ cộng hưởng này có tác dụng khuếch đại 1 vài tần số, triệt tiêu một vài tần số khác để tạo ra âm thanh. Khả năng thay đổi hình dạng linh hoạt của nó giúp tạo ra các âm thanh khác nhau để hình thành lên tiếng nói.



Hình ảnh trên đây mô tả rất chi tiết về cơ chế **Source + Filter → Output sound**

Tại spectrum của output sound, ta thấy có 3 đỉnh, các đỉnh này lần lượt gọi là đỉnh F1, F2, F3 ...hay còn gọi là các **formant**. Giá trị, vị trí, sự thay đổi theo thời gian của các đỉnh này đặc trưng cho các âm vị. Trong các phương pháp nhận dạng tiếng nói truyền thống, người ta sẽ cố gắng tách thông tin về các **formant** này ra khỏi **F0** rồi mới sử dụng thông tin này để nhận dạng.

Mô hình Nguồn - Bộ lọc (Source-Filter Model)

[Dây thanh đới rung] ---> Tạo ra Sóng hài (Harmonics: $f_0, 2f_0, 3f_0 \dots$)

↓

[Khoang họng & miệng] ---> Khuếch đại một số dải tần số cụ thể ---> Tạo ra Formants ($F_1, F_2 \dots$)


$$\text{Nguồn phát (Source - Dây thanh đới)} \times \\ \text{Bộ lọc (Filter - Khoang miệng, môi, lưỡi)} = \text{Âm thanh phát ra}$$

Sóng hài (Harmonics)

Bản chất: Khi bạn nói hoặc hát ở một cao độ nhất định, dây thanh đới rung lên với tần số cơ bản là f_0 (Pitch). Sự dao động này tự động sinh ra một chuỗi các bội số nguyên của f_0 . Sóng hài của tiếng nói (hài âm hay bồi âm) là các thành phần sóng âm có tần số là bội số nguyên của tần số cơ bản, quyết định âm sắc và đặc trưng của giọng nói.

$$\text{Harmonics} = \{f_0, 2f_0, 3f_0, 4f_0, \dots\}$$

Ví dụ: Nếu bạn phát âm nốt La ($f_0 = 100$ Hz), các sóng hài sẽ xuất hiện cách đều nhau tại 200 Hz, 300 Hz, 400 Hz, ...




Formants

Bản chất: Khi luồng sóng hài đi qua khoang họng, miệng và mũi, hình dáng khẩu hình của bạn sẽ hoạt động như một bộ lọc cộng hưởng: nó dập tắt một số tần số và khuếch đại mạnh một số vùng tần số khác.

Định nghĩa: Formant là các đỉnh cộng hưởng năng lượng (Resonance Peaks) của đường dẫn âm thanh, ký hiệu là F_1 , F_2 , F_3 , ...

- F_1 (Formant thứ nhất): Liên quan đến độ mở của hàm (cằm mở rộng thì F_1 tăng) hoặc độ cao-thấp của lưỡi.
- F_2 (Formant thứ hai): Liên quan đến vị trí trước-sau của lưỡi (lưỡi đưa ra trước thì F_2 tăng).
- F_3 (Formant thứ ba): Định hình các chi tiết sâu hơn của âm sắc, phối hợp tạo nên "vân tay giọng nói" riêng biệt của mỗi người.



Âm học thính giác (Psychoacoustics)


Âm học thính giác (Psychoacoustics) giải quyết một vấn đề cốt lõi: Cách tai và não người cảm nhận âm thanh rất khác so với cách máy móc đo đạc.

Máy móc đo đạc vật lý dựa trên các thang đo tuyến tính:

- Tần số vật lý (Hz): Số dao động trong một giây.
- Cường độ âm ($dB / W/m^2$): Năng lượng của sóng âm.

Nhưng tai người không phải là một chiếc micro hoàn hảo. Hệ thính giác có cơ chế cảm nhận phi tuyến tính cả về độ cao (Pitch) lẫn độ to (Loudness).

Khi âm thanh truyền tới tai và đập vào màng nhĩ, màng nhĩ rung lên, truyền rung động lên 3 xương nhỏ: malleus, incus, stapes tới ốc tai. Ốc tai là 1 bộ phận dạng xoắn, rộng như 1 con ốc. Ốc tai chứa các dịch nhầy bên trong giúp truyền âm thanh, dọc theo ốc tai là các tế bào lông cảm nhận âm thanh. Các tế bào lông này rung lên khi có sóng truyền qua và gửi tín hiệu tới não bộ. Các tế bào ở đoạn đầu cứng hơn, rung động với các tần số cao. Càng sâu vào trong, các tế bào càng bớt cứng, đáp ứng các tần số thấp. Do cấu tạo ốc tai cùng số lượng các tế bào đáp ứng tần số thấp chiếm phần lớn khiến cho việc cảm nhận của tai người (và động vật) là phi tuyến tính, nhạy cảm ở tần số thấp, kém nhạy cảm ở tần số cao.



Trong xử lý tiếng nói, ta cần 1 cơ chế để map giữa tín hiệu âm thanh thu được bằng cảm biến và độ cảm nhận của tai người. Việc map này được thực hiện bởi **Mel filterbank**

Cảm nhận về độ cao (Pitch Perception)

Các nghiên cứu đã chỉ ra rằng con người không cảm nhận được tần số trên thang đo tuyến tính. Con người có thể dễ dàng phân biệt được âm thanh với tần số thấp hơn tần số cao. Hầu hết con người có thể dễ dàng nhận ra sự khác biệt giữa âm thanh 100 Hz và 200 Hz nhưng lại khó nhận ra sự khác biệt giữa 2000 và 2100 Hz, mặc dù khoảng cách giữa hai bộ âm thanh là như nhau. Đây là cách con người cảm nhận các tần số

Khi tần số tăng đều đặn theo cấp số cộng (+500 Hz), tai người không nghe thấy nốt nhạc cao lên một khoảng đều nhau:

- Từ 200 Hz → 700 Hz: Bạn thấy âm thanh cao vọt lên rất rõ ràng.
- Từ 10.000 Hz → 10.500 Hz: Bạn gần như không nhận ra sự khác biệt.

Tai người rất nhạy cảm với sự thay đổi ở tần số thấp (nơi chứa hầu hết thông tin tiếng nói con người: 300 Hz – 4.000 Hz) và kém nhạy dần ở tần số cao.

Tần số 200Hz → Tần số 700Hz

Tần số 10000Hz → Tần số 10500Hz

Thang đo Mel (Mel Scale)

- **Ý tưởng:** Thang đo dựa trên thí nghiệm tâm lý âm học (gốc từ chữ *Melody*). Người ta quy ước âm thanh chuẩn 1.000 Hz ở 40 dB tương ứng với 1000 Mel.
- **Đặc điểm:**
 - Dưới 1.000 Hz: Quan hệ giữa Mel và Hz gần như là đường thẳng tuyến tính.
 - Trên 1.000 Hz: Quan hệ trở thành hàm Logarithmic (đường cong nén lại).
- **Công thức chuyển đổi phổ biến:**

$$m = 2595 \times \log_{10} \left(1 + \frac{f}{700} \right)$$

- **Ứng dụng:** Là nền tảng để tạo ra **Mel-Filterbank**, thành phần chính trong **Mel-Spectrogram** và **MFCC (Mel-Frequency Cepstral Coefficients)** — đầu vào của 99% các mô hình ASR (Whisper, Conformer) và TTS (FastSpeech, VITS).


Thang đo Bark (Bark Scale)

- **Ý tưởng:** Đặt theo tên nhà vật lý Heinrich Barkhausen, dựa trên cấu trúc sinh học của **Ốc tai (Cochlea)**.
- **Dải tới hạn (Critical Bands):** Ốc tai chia màng đáy thành 24 dải lọc tự nhiên (tương ứng với 24 vạch Bark từ 1 đến 24). Nếu hai âm thanh có tần số rơi vào cùng một dải tới hạn, tai người sẽ hòa lẫn chúng lại (hiện tượng che lấp - masking).

- **Ứng dụng:** Thường dùng trong các thuật toán nén âm thanh như MP3, AAC và các kỹ thuật khử nhiễu giọng nói (Speech Enhancement).


Mel scale

$$M(f) = 1127 \ln(1 + f/700)$$



Bark scale

$$b(f) = 13 \arctan(0.00076f) + 3.5 \arctan((f/7500)^2)$$



Cảm nhận về độ to (Loudness Perception): Equal-Loudness Contours

Nếu bạn phát hai âm thanh có **cùng cường độ đo được bằng máy là 60 dB**:

- Một âm ở tần số 50 Hz (âm trầm, bass rất sâu).
- Một âm ở tần số 3.000 Hz (tiếng thì thầm / tiếng khóc của trẻ em).


Kết quả: Bạn sẽ nghe thấy âm 3.000 Hz to và chói hơn rất nhiều, còn âm 50 Hz nghe rất nhỏ hoặc gần như không nghe thấy.

Âm 50 Hz (Âm trầm sâu): [Nghe trên YouTube](#)

Âm 3.000 Hz (Âm trung cao / Chói): [Nghe trên YouTube](#)

Đường cong đẳng độ to (Fletcher-Munson / ISO 226)

- **Định nghĩa:** Là tập hợp các đường cong trên đồ thị (Tần số f vs Mức áp suất âm SPL theo dB) mà tại mọi điểm trên cùng một đường cong, tai người cảm nhận **độ to là như nhau**.
- **Đơn vị Phon:** Đường cong đi qua mức X dB tại tần số chuẩn 1.000 Hz được gọi là đường X phon.



- Trục hoành (Trục X - Tần số Hz): Biểu diễn tần số âm thanh từ 20 Hz đến 20.000 Hz theo thang đo Logarit.
- Trục tung (Trục Y - Mức áp suất âm thanh dB SPL): Cường độ âm thanh đo được bằng máy móc thực tế (từ 0 dB đến ≈ 120 dB).
- Mỗi đường cong: Đại diện cho một mức độ to cảm nhận nhất định (tính bằng đơn vị Phon). Mọi điểm nằm trên cùng một đường cong đều được tai người cảm nhận có độ to như nhau.

Vùng "trũng sâu" tại 2 kHz – 5 kHz (Nhạy cảm nhất): Tại dải tần này, đường cong hạ xuống mức dB SPL thấp nhất. Tai người cực kỳ nhạy cảm với dải tần này do cấu tạo ống tai tạo ra hiện tượng cộng hưởng tự nhiên. Chỉ cần một năng lượng vật lý rất nhỏ (chỉ khoảng vài dB hoặc thậm chí 0 dB SPL tại điểm cực tiểu ≈ 3.5 kHz), tai người đã nghe thấy rất rõ.

Vùng dốc ngược ở tần số thấp (< 200 Hz - Âm trầm/Bass): Để tai nghe thấy một âm thanh 30 Hz to tương đương với âm 1 kHz ở 40 phon, máy móc phải phát ra mức năng lượng lên tới hơn 80 dB SPL (gấp hàng ngàn lần về mặt công suất). Tai người rất "lì" và kém nhạy với âm trầm ở mức âm lượng thấp.

Đường dưới cùng (Threshold of Hearing - Ngưỡng nghe tối thiểu): Đường cong nằm dưới cùng (có chữ *threshold*) là mức áp suất âm thanh tối thiểu để tai người khỏe mạnh bắt đầu phát hiện ra có âm thanh tồn tại.

Đường trên cùng (Threshold of Pain - Ngưỡng chói / Đau tai): Ở mức âm lượng cực cao ($\approx 100 - 120$ phon), các đường cong có xu hướng **phẳng dần ra**. Điều này giải thích tại sao khi bạn nghe nhạc ở mức âm lượng rất lớn (như trong Club/Bar), bạn sẽ cảm thấy dải bass, mid và treble đều rõ và cân bằng hơn lúc nghe nhỏ.

Ứng dụng:

- Khi nghe ở âm lượng nhỏ (đường cong phía dưới), dải bass bị suy giảm cảm nhận rất mạnh. Mạch Loudness sẽ tự động nâng tần số thấp lên để bù đắp theo đường cong này.
- Dựa vào ngưỡng nghe dưới cùng để bỏ qua hoàn toàn các âm thanh nằm dưới đường cong (vì tai người không thể nghe thấy), giúp giảm dung lượng file nén tối đa.

Khái niệm	Yếu tố vật lý	Cảm nhận của tai	Ứng dụng chính trong AI Tiếng nói
Mel / Bark Scale	Tần số (Hz)	Cao độ (Pitch)	Trích xuất đặc trưng phổ: Mel-Spectrogram, MFCC
Equal-Loudness	Mức áp suất âm (dB)	Độ to (Loudness)	Xử lý cân bằng âm (Equalization), Nén audio (MP3), Loss Function âm thanh