


Cửa sổ hòa (Windowing)


Vấn đề Rò rỉ phổ (Spectral Leakage): Việc cắt khung đột ngột tạo ra sự gián đoạn mạnh ở đầu và cuối khung. Khi thực hiện FFT, máy tính coi sự gián đoạn này là một "bậc thang" tần số vô hạn, làm cho năng lượng của một tần số chính xác bị rò rỉ sang các tần số lân cận, tạo ra các "thùy bên" (sidelobes) nhiễu lớn. Tham khảo: <http://saadahmad.ca/fft-spectral-leakage-and-windowing/>


Giải pháp: Sử dụng các hàm cửa sổ làm mượt. Các hàm này có giá trị gần 0 ở hai biên và gần 1 ở trung tâm, giúp giảm mượt mà về 0 ở hai mép biên:

$$x_w[n] = x_m[n] \cdot w[n], \quad 0 \leq n \leq N - 1$$



Hình trên đây sẽ cho ta thấy rõ được tác dụng của các window này. Trong các hình nhỏ, hình 1 là frame được cắt ra từ âm thanh gốc, âm thanh gốc là sự kết hợp của 2 sóng hình 2. Nếu áp dụng rectangle window (tức là cắt trực tiếp), tín hiệu miền tần số tương ứng là hình 3, ta có thể thấy tín hiệu này chứa rất nhiều nhiễu. Nếu áp dụng các window như Hanning, Hamming, Blackman, tín hiệu miền tần số thu được khá mượt và sóng gốc ở hình 2.





Các hàm cửa sổ phổ biến:

1. **Cửa sổ chữ nhật (Rectangular):** $w[n] = 1$. Rò rỉ phổ mạnh nhất. Chỉ dùng khi tín hiệu lấp đầy chính xác khung FFT.
2. **Cửa sổ Hann:** Có dạng hình quả chuông, biên giảm về đúng 0. Làm mượt rất tốt, thường dùng trong Spectrogram.

$$w[n] = 0.5 - 0.5 \times \cos\left(\frac{2\pi n}{N-1}\right)$$


3. **Cửa sổ Hamming:** Tương tự Hann nhưng không giảm biên về 0 hoàn toàn. Nó tối ưu hóa để làm thùy bên nhỏ nhất, phổ biến trong các thuật toán trích xuất đặc trưng đời cũ hơn (như MFCC).

$$w[n] = 0.54 - 0.46 \times \cos\left(\frac{2\pi n}{N-1}\right)$$


Loại Cửa Sổ	Biên độ ở biên	Ứng dụng phổ biến nhất
Rectangular	1.0	(Hiếm khi dùng trong Audio)
Hanning	0.0	Tạo Spectrogram (mặc định trong torchaudio)
Hamming	≈ 0.08	Thuật toán MFCC, Coder




Rectangular



Hamming



Hanning



(Taylor, fig 12.1)


Voice Activity Detection (VAD)


Trong một file thu âm thực tế, khoảng lặng và tiếng ồn nền thường chiếm từ 20% – 40% thời lượng. VAD là kỹ thuật xác định chính xác phân đoạn nào chứa tiếng nói con người (Speech) và phân đoạn nào là khoảng lặng/nhiều (Non-speech).

Năng lượng khung ngắn (Short-Time Energy - STE): Khung chứa giọng nói thường có năng lượng cao hơn rõ rệt so với khoảng lặng/nhiều nền.

$$E = \sum_{n=0}^{N-1} x^2[n]$$

Tỷ lệ cắt qua điểm không (Zero-Crossing Rate - ZCR): Đếm số lần tín hiệu đổi dấu âm/dương. Tiếng nói (đặc biệt là nguyên âm) có ZCR thấp do tính tuần hoàn, trong khi nhiễu trắng hoặc phụ âm gió có ZCR rất cao.





- **Phương pháp truyền thống:** Dựa trên ngưỡng năng lượng khung (Short-Time Energy) và tỷ lệ vượt qua điểm không (Zero-Crossing Rate - ZCR).
- **Phương pháp hiện đại:** Sử dụng các mô hình học sâu nhỏ gọn (ví dụ: Silero VAD, WebRTC VAD) cho độ chính xác cao ngay cả trong môi trường nhiễu tạp âm.
- **Lợi ích:** Giảm tải tính toán cho mô hình AI chính và hạn chế hiện tượng mô hình ASR sinh ảo giác (hallucination) khi gặp khoảng lặng dài.

Chuẩn hóa biên độ (Amplitude Normalization)

Mức âm lượng đầu vào giữa các file thu âm có thể chênh lệch rất lớn do khoảng cách đặt micro khác nhau. Chuẩn hóa giúp đưa biên độ tín hiệu về một thang đo thống nhất trước khi nạp vào mạng nơ-ron:

- **Peak Normalization:** Tỷ lệ toàn bộ mẫu tín hiệu theo giá trị biên độ tuyệt đối lớn nhất để đỉnh cao nhất chạm mức tối đa mong muốn (thường là 1.0 hoặc -1 dBFS):

$$x_{\text{norm}}[n] = \frac{x[n]}{\max(|x[n]|)}$$

- **RMS Normalization (Root Mean Square):** Chuẩn hóa dựa trên mức công suất năng lượng trung bình của toàn bộ đoạn âm thanh, giúp các file có cùng mức cảm nhận độ to (Perceived Loudness) tương đồng nhau:

$$x_{\text{rms_norm}}[n] = x[n] \cdot \frac{\text{Target_RMS}}{\sqrt{\frac{1}{L} \sum_{k=0}^{L-1} x^2[k]}}$$

giac (hallucination) khi gặp khoảng lặng dài.

Chuẩn hóa biên độ (Amplitude Normalization)

Mức âm lượng đầu vào giữa các file thu âm có thể chênh lệch rất lớn do khoảng cách đặt micro khác nhau. Chuẩn hóa giúp đưa biên độ tín hiệu về một thang đo thống nhất trước khi nạp vào mạng nơ-ron:

- **Peak Normalization:** Tỷ lệ toàn bộ mẫu tín hiệu theo giá trị biên độ tuyệt đối lớn nhất để đỉnh cao nhất chạm mức tối đa mong muốn (thường là 1.0 hoặc -1 dBFS):

$$x_{\text{norm}}[n] = \frac{x[n]}{\max(|x[n]|)}$$

- **RMS Normalization (Root Mean Square):** Chuẩn hóa dựa trên mức công suất năng lượng trung bình của toàn bộ đoạn âm thanh, giúp các file có cùng mức cảm nhận độ to (Perceived Loudness) tương đồng nhau:

$$x_{\text{rms_norm}}[n] = x[n] \cdot \frac{\text{Target_RMS}}{\sqrt{\frac{1}{L} \sum_{k=0}^{L-1} x^2[k]}}$$