

Biểu diễn Dữ liệu & Tiền xử lý (Feature Engineering)

👤 Người tạo Empty

📁 Module Audio Processing

📁 Trạng thái Empty

☰ Note Empty

📅 Đã trình bày Empty

📁 Sub-module Empty

📁 Submodule 2 Empty

Số lượng thành ... Empty

Comments

 Add a comment...

Chuyển dịch Không gian Biểu diễn từ Sóng thô 1D sang Biểu diễn 2D/3D

Tín hiệu âm thanh tự nhiên trong miền thời gian được lưu trữ dưới dạng sóng thô (raw waveform) 1D, biểu thị sự biến thiên biên độ áp suất không khí theo thời gian $x(t) \in \mathbb{R}^N$. Mặc dù sóng thô bảo toàn toàn bộ thông tin vật lý nguyên bản của môi trường truyền âm, việc trích xuất đặc trưng trực tiếp từ chuỗi thời gian 1D này cho các mô hình học sâu đặt ra những rào cản kỹ thuật nghiêm trọng.

Tín hiệu âm thanh mang bản chất non-stationary, trong đó tần số và năng lượng liên tục biến đổi theo thời gian. Trong biểu diễn 1D, các thành phần tần số bị chồng phủ hoàn toàn trong sự dao động thời gian, khiến các phép tích chập 1D (1D-CNN) rất khó phát hiện được các cấu trúc hài âm (harmonics), âm sắc (timbre) hay các mẫu ngữ âm phức tạp.

Để vượt qua giới hạn này, ta chuyển đổi sóng 1D sang không gian biểu diễn 2D (Thời gian - Tần số) hoặc 3D (Kênh - Thời gian - Tần số). Phép chuyển đổi này mở ra khả năng tái cấu trúc âm thanh thành các dạng ảnh phổ (**Spectrograms**), cho phép khai thác sức mạnh của mạng tích chập 2D (2D-CNN), Vision Transformers (ViT) và các cơ chế chú ý (Self-Attention).

Phân tích miền thời gian và miền tần số

Biến đổi Fourier chuẩn (FFT) chuyển toàn bộ tín hiệu thành một phổ tần số $X[k]$, trả lời câu hỏi "Có những tần số nào?" nhưng mất hoàn toàn thông tin "Khi nào chúng xuất hiện?".

Nếu tín hiệu thay đổi theo thời gian (ví dụ: tiếng nói, chứa các âm tiết khác nhau nối tiếp nhau), FFT chuẩn sẽ hòa trộn tất cả các âm tiết này thành một phổ mờ nhạt. Ta cần một kỹ thuật biết "chụp ảnh" phổ tần số tại từng thời điểm nhỏ.

Biểu đồ trong Time Domain rất hữu ích để xem cách âm thanh thay đổi theo thời gian. Nó cho chúng ta biết mức độ âm thanh tại mỗi thời điểm và giúp chúng ta nhận diện các thay đổi trong âm thanh, như khi một nhạc cụ bắt đầu hoặc dừng chơi.

Biểu đồ trong Frequency Domain lại rất hữu ích để hiểu thành phần của âm thanh. Nó cho chúng ta biết các tần số nào đang có mặt trong âm thanh và cường độ của từng tần số. Điều này rất quan trọng trong nhiều ứng dụng, chẳng hạn như phân tích nhạc, nhận diện giọng nói, và kỹ thuật âm thanh.

Bằng cách kết hợp cả hai loại biểu đồ này, chúng ta có thể có được một cái nhìn toàn diện về tín hiệu âm thanh, từ cách nó thay đổi theo thời gian đến thành phần tần số của nó. Điều này giúp chúng ta hiểu rõ hơn về âm thanh và cách nó được tạo ra, xử lý và nhận diện. Đó là lý do STFT ra đời.

Tạo Spectrogram - Short-Time Fourier Transform (STFT)

Để biết được sự thay đổi của tần số theo thời gian, **STFT** chia tín hiệu thành các phân đoạn ngắn chồng lấp nhau (coi là gần dừng) và áp dụng FFT lên từng đoạn.


Phép biến đổi STFT được thiết lập theo công thức:

$$X(m, k) = \sum_{n=0}^{N-1} x[n + mH] \cdot w[n] \cdot e^{-j \frac{2\pi}{N} kn}$$

Trong đó:

- m : Chỉ số khung thời gian (Time frame index).
- k : Chỉ số dải tần số (Frequency bin index).
- $w[n]$: Hàm cửa sổ (Window function) độ dài N .
- H : Bước nhảy (Hop size / Stride).
- N : Kích thước khung tính toán FFT (`n_fft`).


Quy trình thực hiện STFT



1. **Framing (Cắt khung):** Chia tín hiệu thành các khung (Frame) nhỏ bằng nhau. Độ dài mỗi khung thường là 10-40 ms (N mẫu).
2. **Windowing (Áp dụng cửa sổ):** Nhân mỗi khung với một hàm cửa sổ (độ dài N) để giảm hiện tượng méo phổ.

3. **DFT/FFT:** Thực hiện FFT N điểm cho từng khung đã được nhân cửa sổ.
4. **Overlapping (Chồng lấp):** Dịch chuyển cửa sổ một khoảng nhỏ (gọi là *Hop Size* hoặc *Stride*) nhỏ hơn độ dài khung, để đảm bảo không mất thông tin tại các biên của khung trước.

Đầu ra của thuật toán DFT (hoặc FFT) trên một khung là một mảng các số phức, chứa cả thông tin biên độ và pha của các dải tần số. Khi áp dụng cho toàn bộ tín hiệu, kết quả của STFT là một ma trận số phức 2D $X(m, k) \in \mathbb{C}^{M \times K}$ (Thời gian $\times$ Tần số). Từ ma trận này, ta lấy độ lớn biên độ ($|X(m, k)|$ hoặc $|X(m, k)|^2$) để vẽ nên biểu đồ Spectrogram biểu diễn sự biến thiên của phổ theo thời gian.



Trục Y của STFT Spectrogram chuẩn là thang tuyến tính (Hz), trục X là chỉ số khung thời gian (Time / Frame Index) tính theo bước nhảy H (Hop Size).

Phase vs. Magnitude

Sau khi thực hiện FFT trên một khung, kết quả $X[k]$ là một mảng các số phức ($a + bj$). Số phức này chứa hai thông tin quan trọng:

Amplitude/Magnitude (Biên độ - Độ lớn)

- **Công thức:** $|X[k]| = \sqrt{a^2 + b^2}$
- **Ý nghĩa:** Nó cho biết "lượng năng lượng" của tần số f_k có trong khung tín hiệu đó. Hầu hết các đặc trưng dùng cho AI (ASR, Phân loại, Xác thực) đều dựa hoàn toàn vào **Magnitude Spectrogram** vì nó chứa thông tin về các đỉnh formant và cấu trúc hài, quyết định ngữ nghĩa của tiếng nói.

- **Trong Spectrogram:** Spectrogram mà chúng ta "nhìn thấy" chính là *Magnitude* (hoặc thường là $\log(Magnitude)$ hoặc $Power = Magnitude^2$) được biểu diễn bằng màu sắc.


Phase (Pha)


- **Công thức:** $\angle X[k] = \arctan\left(\frac{b}{a}\right)$
- **Ý nghĩa:** Nó cho biết vị trí thời gian tương đối (hoặc độ trễ góc) của sóng hình sin f_k so với điểm bắt đầu của khung. Nó mô tả cách các sóng hài xếp chồng lên nhau để tạo ra hình dạng sóng cụ thể trong miền thời gian, dễ bị nhiễu và khó học. Tuy nhiên, Pha cực kỳ QUAN TRỌNG trong tổng hợp tiếng nói (Speech Synthesis - TTS). Nếu Magnitude Spectrogram đúng nhưng Pha sai, âm thanh khi tổng hợp lại sẽ bị "mù", "đục" hoặc "kỹ thuật số".

Thành phần	Công thức ($X[k]=a+bj$)	Biểu diễn	Ứng dụng trong AI Speech
Magnitude	$\sqrt{a^2 + b^2}$	Spectrogram màu	Dùng cho Input model ASR, VAD, SER
Phase	$\arctan(b/a)$	Góc xoay	Dùng cho tổng hợp lại audio (TTS, Vocoder)

Spectrograms

Biểu diễn trực quan các tần số của một tín hiệu nhất định với thời gian được gọi là Spectrogram. Nó giống như chúng ta chụp spectrum nhiều lần tại các thời điểm khác nhau, sau đó ghép chúng lại thành một biểu đồ duy nhất.





Spectrogram sử dụng các màu sắc khác nhau để biểu diễn cường độ của mỗi tần số. Màu càng sáng, năng lượng của tín hiệu càng cao. Mỗi "lát" dọc của spectrogram thực chất là spectrum của tín hiệu tại thời điểm đó và cho thấy cách phân bố cường độ tín hiệu trong mỗi tần số tại thời điểm đó.

Giả sử bạn có một đoạn ghi âm. Hình ảnh đầu tiên hiển thị tín hiệu trong **Time Domain**, tức là biên độ theo thời gian. Nó cho chúng ta biết mức độ âm thanh to hay nhỏ tại bất kỳ thời điểm nào, nhưng không cung cấp nhiều thông tin về tần số nào đang có mặt.

Hình ảnh thứ hai là **Spectrogram** và hiển thị tín hiệu trong **Frequency Domain**. Nó cho thấy cách các tần số trong tín hiệu thay đổi theo thời gian và cường độ của từng tần số.

Ví dụ, nếu đoạn ghi âm có một nốt nhạc với tần số cơ bản là 200 Hz, cùng với các hài âm ở 400 Hz, 600 Hz, v.v., bạn sẽ thấy các đường sáng tại các tần số này trên spectrogram. Nếu năng lượng của nốt nhạc tăng lên, màu sắc trên spectrogram sẽ trở nên sáng hơn, biểu thị rằng tín hiệu mạnh hơn tại những tần số đó.

Spectrogram là một công cụ mạnh mẽ giúp chúng ta hiểu rõ hơn về tín hiệu âm thanh. Bằng cách xem xét spectrogram, chúng ta có thể thấy cách các tần số trong tín hiệu thay đổi theo thời gian và cường độ của từng tần số. Điều này rất hữu ích trong nhiều lĩnh vực, từ phân tích nhạc, nhận diện giọng nói đến kỹ thuật âm thanh và nghiên cứu khoa học về âm thanh.

Nguyên lý Bất định Thời - Tần (Time-Frequency Uncertainty Principle)

Trong xử lý tín hiệu, nguyên lý bất định Gabor-Heisenberg chỉ ra rằng: **Không thể đồng thời đạt được độ phân giải thời gian cực cao và độ phân giải tần số cực cao trên cùng một phép biến đổi STFT.**

Khoảng không gian phân giải tối thiểu bị ràng buộc bởi bất đẳng thức:

$$\Delta t \cdot \Delta f \geq \frac{1}{4\pi}$$

Trong đó:

- Δt : Độ phân giải thời gian (Thời lượng quan sát của cửa sổ N).
- Δf : Độ phân giải tần số (Khoảng cách tần số nhỏ nhất có thể phân biệt).


Sự đánh đổi khi chọn kích thước cửa sổ (N)

- Khung nhỏ / Cửa sổ ngắn (N bé, ví dụ 5 ms – 10 ms):
 - Δt nhỏ $\rightarrow$ Độ phân giải thời gian cao: Xác định rất chính xác thời điểm một âm thanh bắt đầu hoặc kết thúc (Transient events).
 - Δf lớn $\rightarrow$ Độ phân giải tần số thấp: Các đỉnh tần số nằm sát nhau sẽ bị hòa lẫn thành một vệt mờ, không phân biệt được từng nốt nhạc hay sóng hài riêng lẻ.
- Khung lớn / Cửa sổ dài (N lớn, ví dụ 50 ms – 100 ms):
 - Δt lớn $\rightarrow$ Độ phân giải thời gian thấp: Các âm tiết hoặc tiếng gõ diễn ra liên tiếp nhanh sẽ bị nhòe và trộn lẫn vào nhau theo trục thời gian.
 - Δf nhỏ $\rightarrow$ Độ phân giải tần số cao: Tách bạch rõ từng tần số đơn lẻ (1 Hz hay 2 Hz) và các vạch sóng hài.

So sánh Wideband Spectrogram và Narrowband Spectrogram

Sự đánh đổi này dẫn đến hai trường phái hiển thị Spectrogram trong âm học ngữ âm:


Tiêu chí	Wideband Spectrogram (Cửa sổ ngắn)	Narrowband Spectrogram (Cửa sổ dài)
Kích thước cửa sổ	Ngắn (thường $N \approx 3\text{ ms} - 5\text{ ms}$)	Dài (thường $N \approx 30\text{ ms} - 50\text{ ms}$)
Độ phân giải	Thời gian cao, Tần số thấp	Thời gian thấp, Tần số cao
Hình thái hiển thị	Các dải phổ tần số bị bè rộng tạo thành các vệt nằm ngang lớn (Formants); xuất hiện các vạch sọc đứng thể hiện từng xung mở của dây thanh đới (Glottal pulses).	Xuất hiện các đường kẻ ngang mảnh s rất sắc nét biểu thị từng sóng hài riêng lẻ (Harmonics : $f_0, 2f_0, 3f_0\dots$).
Mục đích phân tích	Phân tích đặc trưng ngữ âm (Phonetics) , vị trí cộng hưởng của khoang miệng (Formants F_1, F_2) và các phụ âm bật ngắn ($/p/, /t/, /k/$).	Phân tích cao độ (Pitch) , tần số cơ bản và sự biến thiên giai điệu trong giọng nói.



Vì các sóng hài nằm rất sát nhau (chỉ cách nhau 100 Hz), bạn cần độ phân giải tần số cực cao (Δf nhỏ) để tách rời từng vạch. Do đó, Narrowband Spectrogram (Cửa sổ dài) là công cụ duy nhất nhìn thấy rõ các đường kẻ ngang song song này.

Formant không phải là 1 tần số đơn lẻ mà là cả một dải năng lượng rộng lớn bao trùm nhiều sóng hài. Khi dùng Wideband Spectrogram (Cửa sổ ngắn), độ phân giải tần số bị cố tình làm mờ đi (Δf lớn), khiến các sóng hài đơn lẻ bị hòa tan vào nhau và nổi bật lên các vệt năng lượng đậm màu nằm ngang (Formant Tracks).

Hình dưới là các spectrogram của 4 nguyên âm. Quan sát spectrogram lần lượt từ dưới lên, người ta nhận thấy có 1 vài tần số đặc trưng gọi là các **formant**, gọi là các tần số F1, F2, F3 ... Các chuyên gia về ngữ âm học có thể dựa vào vị trí, thời gian, sự thay đổi các formant trên spectrogram để xác định đoạn âm thanh đó là của âm vị nào.



Đặc trưng Phổ Cơ bản (Spectral Representations)

Linear Spectrogram


Đầu ra của phép biến đổi STFT trên toàn bộ tín hiệu là một ma trận số phức $X(m, k) \in \mathbb{C}^{M \times K}$, trong đó mỗi phần tử có dạng $a + bj$. Để hiển thị thành hình ảnh hoặc đưa vào các mô hình học sâu, ma trận số phức này cần được chuyển đổi thành các dạng biểu diễn phổ số thực (Real-valued Spectrograms).

Phổ biên độ (Magnitude Spectrogram: $|X(t, f)|$)

Phổ biên độ đại diện cho độ lớn biên độ của từng thành phần sóng sin tại mỗi khung thời gian và tần số:

$$|X(m, k)| = \sqrt{\text{Re}(X(m, k))^2 + \text{Im}(X(m, k))^2} = \sqrt{a^2 + b^2}$$

- Đặc tính:** Giữ quan hệ tuyến tính với biên độ điện áp ban đầu của micro ($|X| \propto A$).
- Ứng dụng:** Thường được sử dụng trong các tác vụ phân tích cấu trúc âm học, bóc tách giọng nói (Source Separation) hoặc làm đầu vào trực tiếp cho các thuật toán ước lượng pha (như Griffin-Lim).




Phổ công suất (Power Spectrogram: $|X(t, f)|^2$)

Phổ công suất (còn gọi là Phổ năng lượng - Energy Spectrogram) biểu thị mật độ năng lượng của tín hiệu trên từng dải tần số:

$$P(m, k) = |X(m, k)|^2 = a^2 + b^2$$

- **Đặc tính:** Tỷ lệ thuận với bình phương biên độ, phản ánh đúng công suất vật lý của sóng âm ($P \propto A^2$).
- **Ứng dụng:** Là đầu vào tiêu chuẩn để nhân với ma trận Mel-Filterbank nhằm tạo ra Mel-Spectrogram và MFCCs.



Do tai người cảm nhận âm lượng theo quy luật phi tuyến tính và dải năng lượng âm thanh thực tế chênh lệch rất lớn (lên tới 10^6 lần), việc hiển thị $|X|$ hoặc $|X|^2$ ở thang tuyến tính sẽ khiến các tần số yếu bị chìm hoàn toàn vào màu nền tối. Người ta áp dụng hàm Logarit để nén dải động về thang Decibel (dB):

$$S_{\text{dB}}(m, k) = 10 \log_{10} \left(\frac{|X(m, k)|^2}{P_{\text{ref}}} \right) = 20 \log_{10} \left(\frac{|X(m, k)|}{A_{\text{ref}}} \right)$$

(Trong thực hành, P_{ref} thường chọn là giá trị công suất cực đại $\max(P)$ để đưa toàn bộ dải năng lượng về khoảng $[-\text{top_db}, 0 \text{ dB}]$, với $\text{top_db} \approx 80 \text{ dB}$).

Mặc dù Linear Spectrogram bảo toàn trọn vẹn thông tin năng lượng trên toàn bộ dải tần, nó bộc lộ hạn chế lớn khi mô hình hóa khả năng thính giác của con người. Hệ thống thính giác người phân biệt các tần số thấp một cách tinh vi hơn nhiều so với các tần số cao, khiến biểu diễn tuyến tính trở nên dư thừa dữ liệu ở dải tần cao và thiếu độ phân giải ở dải tần thấp:

- Về tần số (Hz): Spectrogram tiêu chuẩn chia các vạch tần số đều tằm tắp (ví dụ cứ mỗi 50 Hz một vạch từ $0 \rightarrow 8000 \text{ Hz}$). Tuy nhiên, thông tin ngữ nghĩa của giọng nói con người lại tập trung phần lớn ở dải tần thấp (300 Hz – 4000 Hz). Kết quả là vùng dải tần cao chứa rất ít thông tin hữu ích nhưng lại chiếm tới hơn một nửa diện tích hiển thị/kích thước ma trận của Spectrogram.
- Về biên độ: Thang đo biên độ tuyến tính không phản ánh đúng cách tai người cảm nhận âm lượng (vốn theo thang đo Logarit/Decibel).

Dữ liệu có kích thước chiều tần số rất lớn (High Dimensionality) nhưng độ đậm đặc thông tin lại không đồng đều dẫn đến mô hình học máy phải tốn nhiều tham số để học cả những vùng tần số cao "trống rỗng" hoặc không quan trọng, làm tăng chi phí tính toán và giảm hiệu năng nhận dạng.

Mel-Spectrogram

Mel-Spectrogram giải quyết nhược điểm của Linear Spectrogram bằng cách ánh xạ dải tần tuyến tính (Hz) sang Thang đo Mel (Mel Scale). Thang Mel là một thang đo tần số phi tuyến tính, được xây dựng dựa trên các thực nghiệm tâm lý âm học (psychoacoustics) nhằm mô phỏng phản ứng của các bộ lọc dải tai trong màng cơ sở (basilar membrane) của tai người. Công thức chuyển đổi giữa tần số tuyến tính f (Hz) và giá trị Mel m_{mel} được xác định bởi:

$$m_{\text{mel}} = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$$

Khởi tạo Mel-Filterbank

Quá trình khởi tạo Mel-Spectrogram đòi hỏi việc nhân phổ công suất $P(m, k)$ với một Ma trận Dải lọc Mel (Mel Filter Bank) $M \in \mathbb{R}^{M_{\text{mel}} \times K}$. **Mel-Filterbank** được thiết kế để nén và tái cấu trúc phổ tần số theo cảm nhận của màng cơ sở trong ốc tai người. Ma trận này bao gồm một chuỗi các bộ lọc hình tam giác xếp chồng lên nhau có độ rộng dải tăng dần theo tần số.

Để xây dựng ma trận dải lọc Mel $\mathbf{M} \in \mathbb{R}^{N_{\text{mels}} \times K}$, quy trình gồm 5 bước toán học sau:

Bước 1: Xác định dải tần số giới hạn (Hz): Xác định tần số thấp nhất ($f_{\min}$) và cao nhất ($f_{\max}$) cần phân tích:

- $f_{\min}$: Thường chọn 0 Hz (hoặc 20 Hz - giới hạn nghe dưới của tai người).
- $f_{\max}$: Thường chọn tần số Nyquist $f_{\text{Nyquist}} = \frac{f_s}{2}$ (ví dụ 8000 Hz với tín hiệu có $f_s = 16$ kHz).

Bước 2: Chuyển đổi dải tần sang thang Mel: Áp dụng công thức chuyển đổi từ tần số vật lý f (Hz) sang giá trị cảm nhận m (Mel):

$$m_{\min} = 2595 \cdot \log_{10} \left(1 + \frac{f_{\min}}{700} \right)$$

$$m_{\max} = 2595 \cdot \log_{10} \left(1 + \frac{f_{\max}}{700} \right)$$

Bước 3: Chia đều các điểm mốc trên thang Mel: Để tạo ra N_{mels} bộ lọc hình tam giác xếp liền kề nhau, ta chia đoạn $[m_{\min}, m_{\max}]$ thành $N_{\text{mels}} + 1$ khoảng bằng nhau, tương ứng với $N_{\text{mels}} + 2$ điểm mốc cách đều:

$$\Delta m = \frac{m_{\max} - m_{\min}}{N_{\text{mels}} + 1}$$

$$m_i = m_{\min} + i \cdot \Delta m \quad \text{với } i = 0, 1, 2, \dots, N_{\text{mels}} + 1$$

Bước 4: Chuyển các điểm mốc về Hz và ánh xạ sang chỉ số FFT Bin

- **Đổi từ Mel ngược về Hz:**

$$f_i = 700 \cdot \left(10^{\frac{m_i}{2595}} - 1\right)$$

- **Ánh xạ tần số f_i về chỉ số bin FFT (k_i):** Với kích thước FFT là N_{fft} , ta làm tròn về số nguyên gần nhất:

$$k_i = \left\lfloor \frac{(N_{\text{fft}} + 1) \cdot f_i}{f_s} \right\rfloor$$

Ta thu được dãy gồm $N_{\text{mels}} + 2$ chỉ số bin tần số: $\{k_0, k_1, k_2, \dots, k_{N_{\text{mels}}+1}\}$.

Bước 5: Thiết lập hàm truyền hình tam giác cho từng bộ lọc: Mỗi bộ lọc thứ m ($1 \leq m \leq N_{\text{mels}}$) là một hàm tam giác bắt đầu tại k_{m-1} , đạt đỉnh bằng 1 tại k_m , và kết thúc tại k_{m+1} :

$$H_m(k) = \begin{cases} 0 & \text{khi } k < k_{m-1} \\ \frac{k - k_{m-1}}{k_m - k_{m-1}} & \text{khi } k_{m-1} \leq k \leq k_m \\ \frac{k_{m+1} - k}{k_{m+1} - k_m} & \text{khi } k_m \leq k \leq k_{m+1} \\ 0 & \text{khi } k > k_{m+1} \end{cases}$$

Sau khi tính toán cho tất cả các bộ lọc, ta xếp chồng chúng lại để thu được ma trận $\mathbf{M} \in \mathbb{R}^{N_{\text{mels}} \times K}$ (với $K = \frac{N_{\text{fft}}}{2} + 1$).

Mel-Spectrogram & Log-Mel Spectrogram


Ta tính tích ma trận giữa ma trận dải lọc Mel $\mathbf{M}$ và ma trận Phổ công suất $\mathbf{P} \in \mathbb{R}^{K \times T}$ (thu được từ $|X(t, f)|^2$ của STFT):

$$\mathbf{S}_{\text{mel}} = \mathbf{M} \cdot \mathbf{P}$$

Ma trận kết quả $\mathbf{S}_{\text{mel}}$ có kích thước $(N_{\text{mels}} \times T)$. Giá trị tại dải Mel thứ m và khung thời gian t là tổng năng lượng có trọng số của các bin tần số tuyến tính:

$$S_{\text{mel}}(m, t) = \sum_{k=0}^{K-1} M(m, k) \cdot P(k, t)$$

- **Dải tần số thấp:** Các bộ lọc tam giác hẹp $\rightarrow$ Giữ nguyên chi tiết từng dải tần nhỏ.
- **Dải tần số cao:** Các bộ lọc tam giác rộng $\rightarrow$ Gộp năng lượng của nhiều dải tần Hz lại thành một giá trị tổng hợp.



Biên độ năng lượng âm thanh thực tế có thể chênh lệch nhau tới hàng triệu lần (10^6), trong khi tai người cảm nhận độ to theo hàm logarit. Để cân bằng biên độ và ổn định quá trình tối ưu hóa gradient cho mạng nơ-ron, ta áp dụng phép biến đổi logarit:

$$S_{\text{log-mel}} = \log(S_{\text{mel}} + \epsilon)$$


(Với $\epsilon \approx 10^{-5}$ là hằng số cực nhỏ giúp tránh lỗi $\log(0)$ khi gặp khoảng lặng).

Trong thực tế kỹ thuật, người ta quy đổi sang thang Decibel (dB) so với năng lượng đỉnh:

$$S_{\text{dB}}(m, t) = 10 \log_{10} \left(\frac{S_{\text{mel}}(m, t)}{\max(S_{\text{mel}}) + \epsilon} \right)$$

Sau đó, dải giá trị được cắt ngưỡng (clipping) trong khoảng $[-\text{top_db}, 0 \text{ dB}]$ (thường chọn $\text{top_db} = 80 \text{ dB}$).

Việc giảm số dải tần từ hàng nghìn bin tuyến tính xuống còn 80 hoặc 128 dải Mel giúp nén không gian biểu diễn một cách hiệu quả nhưng vẫn bảo toàn tối đa các đặc trưng ngữ âm quan trọng. Log-Mel Spectrogram hiện là biểu diễn chuẩn mực hàng đầu cho các mô hình nhận dạng tiếng nói (ASR) và tổng hợp tiếng nói (TTS) tiên tiến.



Ứng dụng trong các kiến trúc Deep Learning hiện đại

Log-Mel Spectrogram là dạng biểu diễn thay thế cho Waveform 1D trong các bài toán AI âm thanh:

- ASR (Nhận dạng tiếng nói): Các mô hình như OpenAI Whisper, Conformer, Zipformer sử dụng trực tiếp Log-Mel Spectrogram ($N_{\text{mels}} = 80$ hoặc 128) làm đầu vào cho Audio Encoder kết hợp kỹ thuật tăng cường dữ liệu SpecAugment.
- TTS (Tổng hợp giọng nói): Các mô hình kiến trúc âm học như FastSpeech 2, Tacotron 2, VITS dự đoán trực tiếp Log-Mel Spectrogram ở tầng ẩn trước khi nạp vào Vocoder.
- Audio Classification: Đưa ma trận ($N_{\text{mels}} \times T$) vào các mạng nơ-ron tích chập 2D (2D-CNN, ResNet) hoặc Vision Transformers (AST - Audio Spectrogram Transformer) như một bức ảnh đơn kênh.

Mel-Frequency Cepstral Coefficients (MFCCs)

Trước kỷ nguyên Deep Learning, Log-Mel Spectrogram có một hạn chế đối với các thuật toán Machine Learning truyền thống (GMM-HMM, SVM): Các dải lọc tam giác nằm gối đầu lên nhau dẫn đến các giá trị dải Mel có độ tương quan (Correlation) rất cao. MFCCs được sinh ra nhằm giải tương quan (Decorrelation) và nén dữ liệu tối đa.

Mel-Frequency Cepstral Coefficients (MFCCs) đại diện cho dạng biểu diễn nén phổ kinh điển trong xử lý tiếng nói, dựa trên Mô hình Nguồn - Bộ lọc (Source - Filter Model) của cơ quan phát âm người. Mô hình này giả định tín hiệu tiếng nói là sự kết hợp giữa nguồn âm thanh từ dây thanh (glottal excitation) và bộ lọc thanh quản (vocal tract filter). MFCCs bóc tách bao phổ (spectral envelope - đại diện cho bộ lọc thanh quản chứa thông tin nguyên âm/phụ âm) ra khỏi cấu trúc hài âm mịn (fine structure - đại diện cho cao độ nguồn âm).

Cơ chế tách Cepstrum theo Mô hình Nguồn - Bộ lọc

Tín hiệu âm thanh $x[n]$ là tích chập giữa luồng khí dây thanh đới $e[n]$ (Source) và đáp ứng xung khoang miệng $h[n]$ (Filter):

$$x[n] = e[n] * h[n]$$

Khi chuyển sang miền tần số:


$$|X(f)| = |E(f)| \cdot |H(f)|$$


Lấy log hai vế, phép nhân trở thành phép cộng:

$$\log |X(f)| = \log |E(f)| + \log |H(f)|$$

- $\log |H(f)|$: Đường bao phổ biến thiên chậm (Spectral Envelope) chứa các Formants ($F_1, F_2, \dots$) quyết định âm vị nguyên âm/phụ âm.
- $\log |E(f)|$: Dao động răng cưa biến thiên nhanh (Residue) chứa thông tin tần số cơ bản F_0 (Pitch).

Như đã mô tả ở phần trước, giọng nói của chúng ta có tần số F_0 - tần số cơ bản và các **formant** $F_1, F_2, F_3 \dots$ Tần số F_0 ở nam giới khoảng 125 Hz, ở nữ là 210 Hz, đặc trưng cho cao độ giọng nói ở từng người. Thông tin về cao độ này không giúp ích trong nhận dạng giọng nói, nên ta cần tìm cách để loại thông tin về F_0 đi, giúp các mô hình nhận dạng không bị phụ thuộc vào cao độ giọng từng người.





Trong hình này, tín hiệu chúng ta thu được là đồ thị 3, nhưng thông tin quan trọng chúng ta cần là phần 2, thông tin cần loại bỏ là phần 1.

Biến đổi Cosin rời rạc (DCT - Discrete Cosine Transform)

Tương tự như biến đổi Fourier nhưng chỉ dùng hàm cos số thực. DCT nén hầu hết năng lượng của tín hiệu vào vài hệ số đầu tiên và làm triệt tiêu sự phụ thuộc chéo giữa các đặc trưng (Decorrelation) giao giúp tạo ra các đặc trưng độc lập tuyến tính, giúp các mô hình Machine Learning truyền thống hội tụ tốt mà không bị quá khớp (overfitting).

Để tách hai thành phần trên và loại bỏ tương quan giữa các dải Mel, ta áp dụng phép biến đổi DCT loại II lên trục tần số của ma trận Log-Mel Spectrogram:

$$C(n) = \sum_{m=0}^{N_{\text{mels}}-1} S_{\text{log-mel}}(m) \cdot \cos\left(\frac{\pi n(2m+1)}{2N_{\text{mels}}}\right), \quad n = 0, 1, \dots, N_{\text{mfcc}} - 1$$

Miền Quefrency (Cepstral Domain): Phép biến đổi DCT coi phổ như một dạng sóng và phân tích tần số của phổ đó:

- Dao động chậm (Formants): Tương ứng với "tần số thấp của phổ" → Gom toàn bộ vào 12–13 hệ số đầu tiên (Low Quefrency).
- Dao động nhanh (F_0 / Cao độ): Tương ứng với "tần số cao của phổ" → Rơi vào các hệ số phía sau (High Quefrency).

Người ta thường chỉ giữ lại 12 – 13 hệ số đầu tiên (Low-order cepstral coefficients) đại diện cho đường bao phổ ngữ âm (đặc trưng ngữ âm từ khoang miệng), và loại bỏ các hệ số bậc cao chứa thông tin dao động nguồn thanh (cao độ riêng của từng người (F_0))

Đạo hàm động (Δ và $\Delta\Delta$ - Delta & Delta-Delta Features)

Các hệ số MFCCs cơ bản chỉ đại diện cho đặc trưng tĩnh tại từng khung thời gian riêng lẻ. Để bổ sung thông tin về ngữ cảnh và tốc độ biến thiên âm vị theo thời gian (đặc biệt quan trọng tại các điểm bật của phụ âm), ta tính thêm đạo hàm bậc 1 (Δ) và bậc 2 ($\Delta\Delta$):

$$\Delta c_t = \frac{\sum_{k=1}^K k(c_{t+k} - c_{t-k})}{2 \sum_{k=1}^K k^2}$$

- c_t : Vector 13 hệ số MFCC tính tại khung thời gian t .
- Δc_t : Vận tốc biến thiên ngữ âm (13 chiều).
- $\Delta \Delta c_t$: Gia tốc biến thiên ngữ âm (13 chiều - tính bằng đạo hàm của Δc_t).


Vector đặc trưng tổng hợp = [13 MFCCs, 13 Δ , 13 $\Delta \Delta$] $\rightarrow$ **39** chiều

Quy trình trích xuất MFCCs

- Tính toán Phổ công suất từ tín hiệu thông qua phép biến đổi STFT.
- Nhân phổ công suất với Ma trận Dải lọc Mel để thu được năng lượng dải Mel.
- Lấy logarit của năng lượng dải Mel để chuyển các phép nhân tần số thành phép cộng trong miền log.
- Áp dụng Phép biến đổi Cosine Rời rạc (Discrete Cosine Transform - DCT Type-II) trên trục dải Mel để giải tương quan (decorrelate) các năng lượng dải lọc:

$$c_n = \sum_{m=1}^{M_{mel}} \log(S_{mel}[m]) \cdot \cos\left(\frac{\pi n(m - 0.5)}{M_{mel}}\right)$$

- Giữ lại một số lượng nhỏ các hệ số bậc thấp (thường từ 12 đến 20 hệ số) và loại bỏ các hệ số bậc cao chứa nhiều dao động nhanh.



So sánh

Thuộc tính	Linear Spectrogram	Mel-Spectrogram	MFCCs
Bản chất toán học	$ STFT ^2$	$\log(\mathbf{M} \cdot \mathbf{P})$	DCT(Log-Mel)
Miền Không gian	Tần số tuyến tính (Hz)	Thang phi tuyến Mel	Miền Quefrency (Cepstral)
Kích thước Chiều Tần số	Kích thước FFT / 2 + 1 (1025 hoặc 2049)	Thu nhỏ cố định (80, 128, hoặc 256 dải Mel)	Nhỏ (12 đến 20 hệ số đặc trưng)
Đặc tính Toán học & Vật lý	Bảo toàn toàn bộ năng lượng phổ; phân bố dải tần đều theo tuyến tính	Tương thích cảm nhận thính giác; nén thông tin dải cao, giữ chi tiết dải thấp	Giải tương quan tuyến tính; tập trung vào envelope bộ lọc thanh quản
Lĩnh vực Ứng dụng Bắt buộc	Vocoder tái tạo âm thanh, Tách nguồn âm thanh, Phân tích nhạc cụ	Nhận dạng tiếng nói tự động (ASR), Tổng hợp tiếng nói (TTS)	Nhận dạng người nói (Speaker ID), Nhận dạng từ khóa (KWS)
Ưu điểm cốt lõi	Giữ toàn vẹn tần số vật lý (Hz)	Phù hợp sinh học, giữ cấu trúc không gian 2D cho mạng nơ-ron	Dữ liệu độc lập, kích thước siêu nhẹ, nén tối đa
Mô hình tối ưu	Tách nguồn âm (Source Separation)	Deep Learning (Whisper, VITS, CNN, ViT)	ML truyền thống (GMM-HMM, SVM), Speaker ID

Bản chất tính toán: Từng khung → Ghép thành chuỗi (Ma trận)

Với 1 khung đơn lẻ (Thời điểm t):

- Đầu vào: 1 đoạn tín hiệu nhỏ N mẫu ($x_w[n]$).
- STFT/FFT: Biến đổi N mẫu thành 1 vector phổ gồm K phần tử ($K = \frac{N}{2} + 1$).
- Mel Filterbank: Nhân 1 vector phổ (K phần tử) với ma trận Mel để ra 1 vector Mel (N_{mels} phần tử, ví dụ 80).

- Log: Lấy log trên từng phần tử của 1 vector Mel.
- DCT (MFCC): Biến đổi 1 vector Log-Mel (80 phần tử) thành 1 vector Cepstral (12 hoặc 13 phần tử).

Với toàn bộ file âm thanh (Gồm T khung nối tiếp nhau):

- Ta lặp lại quy trình trên cho toàn bộ T khung dọc theo trục thời gian.
- Xếp các vector cột của từng khung cạnh nhau sẽ tạo thành Ma trận 2D (Spectrogram / MFCC Matrix):
 - Linear Spectrogram: Ma trận kích thước $(K \times T)$.
 - Log-Mel Spectrogram: Ma trận kích thước $(N_{\text{mels}} \times T)$ (ví dụ: $80 \times T$).
 - MFCC cơ bản: Ma trận kích thước $(13 \times T)$.

Các đặc trưng nâng cao khác (Tùy chọn)

Chroma Features:

Nhận diện hợp âm, nốt nhạc (Music Information Retrieval).

Zero-Crossing Rate (ZCR) & Spectral Centroid:

Phân biệt nguyên âm/phụ âm và đo độ sáng của âm sắc.